



Universidade Federal de São Paulo

Campus São Jose dos Campos

Processamento de Imagens Médicas

Título

**Avaliação de Modelos de Deep Learning para Diagnóstico de
Tumores Cerebrais em Imagens Médicas**

São Jose dos Campos

2024

I. Introdução

A aplicação da inteligência artificial (IA) no diagnóstico médico por imagens tem avançado significativamente nos últimos anos, principalmente devido à sua eficiência e precisão na identificação de padrões e anomalias. Essa tecnologia oferece análises mais rápidas e de maior abrangência, auxiliando profissionais da saúde a lidar com a crescente demanda por diagnósticos de qualidade. Conforme destacado por Tang (2020), o objetivo principal da IA não é substituir completamente a intervenção humana, mas atuar como uma ferramenta de suporte, especialmente em áreas onde a análise humana pode apresentar limitações. Nesse contexto, uma das aplicações mais promissoras da IA é na geração de pré-diagnósticos baseados em redes neurais treinadas com grandes volumes de dados clínicos (Springer, 2022).

Entre as modalidades de imagem médica, a ressonância magnética (RM) destaca-se por sua crescente relevância no diagnóstico médico. De acordo com Mazzola (2009), a RM tem transformado a prática da neurorradiologia, permitindo a detecção, o diagnóstico, o acompanhamento e o tratamento de uma ampla gama de condições, incluindo tumores cerebrais. Além da RM, outras técnicas, como tomografia computadorizada (TC) e angiografia cerebral, têm possibilitado a visualização detalhada do cérebro e de suas estruturas de maneira não invasiva, favorecendo a identificação de anomalias e lesões. Diferentemente de métodos que utilizam radiação ionizante, como os exames de raios-X, a RM emprega campos magnéticos intensos gerados por ímãs supercondutores para produzir imagens de alta resolução. Esses ímãs são resfriados por hélio líquido, mantidos em condições de supercondutividade para garantir sua eficiência (UFRGS, 2022).

A contribuição da física médica no campo da radiologia tem sido significativa, desde a descoberta dos raios-X por Wilhelm Conrad Roentgen, em 1895, até o desenvolvimento de tecnologias computacionais avançadas. A RM, por exemplo, é amplamente empregada para o diagnóstico de tumores cerebrais, infecções no sistema nervoso central, tendinites e rompimento de

ligamentos, entre outras condições, consolidando-se como uma ferramenta indispensável na prática médica.

No contexto da inteligência artificial, o aprendizado profundo (deep learning) tem se destacado como uma abordagem revolucionária. Essa subárea do aprendizado de máquina (machine learning) utiliza redes neurais artificiais complexas, inspiradas no funcionamento do cérebro humano, para processar grandes volumes de dados de forma autônoma e eficiente. Diferentemente do aprendizado de máquina tradicional, que exige a extração manual de características dos dados, o deep learning é capaz de identificar automaticamente os padrões mais relevantes do conjunto de dados, graças à presença de múltiplas camadas ocultas em suas arquiteturas (AWS, 2023). Essas camadas permitem a otimização e o refinamento da acurácia do modelo, tornando-o especialmente eficaz para tarefas de classificação e segmentação de imagens médicas. No entanto, a aplicação do deep learning requer infraestrutura computacional robusta, como GPUs de alta performance, devido à sua elevada demanda por recursos de hardware (Brownlee, 2016).

Em suma, a combinação da ressonância magnética com técnicas de aprendizado profundo representa um avanço significativo para a área médica, oferecendo diagnósticos mais precisos e um suporte valioso para os profissionais de saúde. Esse progresso ressalta o potencial transformador da inteligência artificial na medicina, promovendo maior acessibilidade e qualidade nos serviços de saúde.

II. Metodologia

Este estudo visou desenvolver e avaliar um modelo de aprendizado profundo para a classificação automática de imagens médicas em quatro categorias: glioma, meningioma, notumor e pituitary. Este tipo de sistema é essencial para auxiliar diagnósticos clínicos, reduzindo o tempo de análise e aumentando a precisão.

A. Dados e Pré-processamento

O *Brain Tumor MRI Dataset* é um conjunto de dados de acesso público utilizado nesta pesquisa [28]. Ele é composto por um total de 7.023 imagens, distribuídas entre 2.000 imagens de cérebros sem tumores, 1.757 imagens de tumores pituitários, 1.621 imagens de tumores gliomas e 1.645 imagens de tumores meningiomas. As imagens foram pre-processadas utilizando as seguintes técnicas, sendo o redimensionamento de todas as imagens para um tamanho fixo de 224 x 224 pixels para compatibilidade com a arquitetura do modelo. A normalização dos valores dos pixels para o intervalo de [0,1]. O Data Augmentation foram aplicadas transformações para aumentar a diversidade do conjunto de treinamento, incluindo rotações, translações e ajustes de brilho.

B. Modelo Proposto

A arquitetura utilizada foi baseada em uma rede neural convolucional (CNN). O modelo foi implementado utilizando a biblioteca Keras com TensorFlow como backend. A estrutura do modelo foi composta pelas seguintes camadas.

- Camada convolucional com filtros de tamanho variados (3 X 3) para extração de características.
- Camada pooling (MaxPooling) para redução da dimensionalidade.
- Camada de regularização com Dropout para evitar overfitting.
- Camadas densas fully-connected com funções de ativação ReLU.
- Camada de saída com função de ativação softmax para classificação de multiclass.

C. MobileNetV2

A MobileNetV2 foi utilizada como base devido a sua eficiência e ao uso de camadas convolucionais depthwise separáveis, que reduzem a complexidade computacional. A base do modelo foi carregada com pesos pré-treinados no

imageNet, a camada de saída foi ajustada para a classificação em quatro categorias, com uma camada densa (fully-connected) e ativação softmax e a camada intermediárias foram congeladas durante as primeiras etapas do treinamento para preservar as características pré-treinadas.

D. ResNet50

A ResNet50 foi selecionada devido a sua profundidade e capacidade de lidar com problemas de degradação e de redes profundas, aproveitando as conexões residuais para melhor propagação de gradiente. A base do modelo foi carregada com pesos pré-treinados no imageNet, para acelerar o treinamento e aproveitar características previamente aprendidas. A última cama foi substituída por uma camada fully-connected com quatro unidades e ativação softmax para classificação das classes do problema. Durante as primeiras etapas de treinamento, as camadas iniciais da ResNet50 foram congeladas para preservar as características pré-treinadas.

E. Parâmetros, Treinamento e Avaliação

Os parâmetros do modelo tiveram com função de perda o “Categorical Crossentropy, com uma otimização “Adam Optimizer” com taxa de aprendizado inicial de 0.001, treinado em 50 épocas e com batch size de 16. Para o treinamento do modelo foi utilizado um ambiente configurado com as seguintes especificações. Hardware foi um processador i7, com 12 GB de RAM e uma GPU RTX 580 de 8 GB. A plataforma de desenvolvimento JupiterLab 3.5.3 do programa Anaconda.Navegador. A validação cruzada utilizou apenas 20% dos dados destinados, e durante o treinamento, as seguintes técnicas foram aplicadas, como o Early Stopping para interromper o treinamento quando a métrica de validação parou de melhorar por 10 épocas consecutivas. O ReduceLROnPlateau para reduzir a taxa de aprendizado em 50% se a métrica

de validação não melhorar por 5 épocas consecutivas e o Checkpoints para salvar os pesos do modelo com o melhor desempenho na validação.

O modelo foi avaliado utilizando as seguintes técnicas: Acurácia global, mostrando o percentual de amostras corretamente classificadas e a matriz de confusão para analisar os erros de classificação em nível de classe. As limitações foram a sobreposição de características entre as classes pode ter contribuído para os erros. Além disso, o hardware utilizado limitou experimentos mais extensivos com redes mais profundas.

III. Resultados

A. Análise de Acurácia




Figura 1 Acurácia e perda do treinamento do modelo proposto.




Figura 2 Acurácia e perda do treinamento e validação MobileNetV2




Figura 3 Acurácia e perda do treinamento e validade do modelo ResNet50

Os gráficos acima apresentam a acurácia de treinamento e validação, onde o treinamento apresenta a capacidade do modelo de se ajustar aos dados que ele já “viu”. A curva crescente indica que o modelo está aprendendo. A validação mede o desempenho em dados que o modelo não “viu” durante o treinamento. Uma curva crescente e estabilizado indica boa generalização. A fig. 1 mostrou uma acurácia de validação estabilizada em 0.82. Isso pode indicar que o modelo está começando a sofrer de underfitting (não conseguindo capturar toda a complexidade dos dados). A perda do conjunto de validação não diminui

tanto quanto o esperado permanecendo um pouco alta em relação ao treinamento. Isto indica problemas de otimização ou desbalanceamento nos dados. A fig. 1 mostra um acurácia de validação de 0.95. Este resultado reflete boa generalização, indicando que o modelo está bem ajustado para ambos os conjuntos. A perda diminui continuamente e estabiliza em torno de 0.25 para validação e treinamento, mostrando um bom equilíbrio. Aqui o modelo conseguiu minimizar os erros de forma eficiente. E a fig. 3 apresenta uma acurácia de validação estabilizada em torno de 0.90, não conseguindo melhorar além disso. Isso pode ser um reflexo de dados desbalanceados, hiper parâmetros inadequados, ou mesmo insuficiência na complexidade do modelo. A perda do conjunto de validação é visivelmente maior, estabilizando entre 0.6 e 0.7. Isso sugere que o modelo não conseguiu capturar totalmente os padrões nos dados de validação.

As figuras 1 e 3 ambos os casos, o modelo não está aprendendo adequadamente a relação entre os dados de entrada e de saída, podendo ser causado por número insuficiente de épocas, modelo muito simples para os dados (baixo número de camadas ou neurônios) ou dados de entrada com ruídos ou irrelevantes. A imagem 2 o modelo parece estar bem otimizado, com alta acurácia de validação e baixa perda. Nenhum dos gráficos apresentaram sinais claros de overfitting (onde a perda de treinamento seria muito menor que a de validação). Isso é um ponto positivo e pode indicar que o modelo foi treinado com regularização apropriada (como dropout ou L2 regularization). Para um aprofundamento na análise, examinar ajustes como taxa de aprendizado, arquitetura do modelo e número de épocas.

B. Matriz de Confusão

As matrizes de confusão fornecem informações essenciais sobre o desempenho de modelos de classificação em dados de teste. Cada matriz é composta por uma tabela de contagem, onde as linhas representam as classes verdadeiras dos dados, as colunas representam as classes preditas pelo modelo e cada célula contém a contagem de amostras que pertencem a classe da linha,

mas foram classificadas na classe da coluna. Os dados analisados indicam um problema de classificação dos dados em quatro classes, sendo elas glioma, meningioma, no tumor e pituitary.




Figura 4 Matriz de confusão do modelo proposto.

A Figura 4 apresenta uma matriz de confusão que ilustra o desempenho do modelo ao classificar as imagens em quatro classes: glioma, meningioma, no tumor e pituitary. A diagonal principal da matriz representa as classificações corretas, com 64 amostras corretamente classificadas como glioma, 75 como meningioma, 119 como no tumor e 73 como pituitary. Observa-se que o modelo apresentou o melhor desempenho na identificação da classe **no tumor**, com 119

classificações corretas, e o desempenho mais limitado na classe **glioma**, com apenas 64 acertos.

Os erros de classificação mais frequentes revelam uma confusão considerável entre as classes. A classe **glioma** foi frequentemente classificada erroneamente como **notumor** (119 casos) e **pituitary** (72 casos). Similarmente, a classe **meningioma** mostrou confusão significativa com **notumor** (105 casos). Já a classe **pituitary** apresentou um número elevado de classificações equivocadas também como **notumor** (104 casos). Esses resultados sugerem que o modelo apresenta maior sensibilidade às características da classe **notumor**, provavelmente devido à predominância de amostras corretamente classificadas nessa categoria.

Essa análise evidencia que o modelo ainda enfrenta desafios para distinguir características específicas de glioma, meningioma e pituitary, especialmente em cenários onde essas classes apresentam semelhanças com a classe **notumor**. Estratégias como ajuste nos hiperparâmetros, balanceamento do conjunto de dados ou a aplicação de técnicas mais robustas de extração de características poderiam ser implementadas para melhorar o desempenho geral e reduzir os erros de classificação.




Figura 5 Matriz de confusão do modelo MobileNetV2.

A Figura 5 apresenta uma matriz de confusão que reflete uma distribuição geral semelhante à da matriz anterior, porém com diferenças sutis nos números de classificações. O modelo classificou corretamente 48 amostras como **glioma**, 64 como **meningioma**, 122 como **notumor** e 78 como **pituitary**. Novamente, o maior desempenho foi observado na identificação da classe **notumor**, com 122 classificações corretas, mostrando uma melhoria em relação à matriz anterior.

Os principais erros de classificação ocorreram na classe **glioma**, que foi equivocadamente classificada como **notumor** em 107 casos e como **pituitary** em 74 casos. A classe **meningioma** também apresentou confusões significativas, sendo frequentemente classificada como **notumor** (103 casos). Já a classe **pituitary**, apesar de ter mostrado melhorias no reconhecimento correto,

ainda apresentou confusões relevantes, sendo classificada erroneamente como **meningioma** em 91 casos e como **notumor** em 77 casos.

Os resultados indicam que o modelo continua a demonstrar uma maior sensibilidade às características da classe **notumor**, como observado anteriormente, mas apresenta uma melhoria na capacidade de classificar corretamente a classe **pituitary**. Contudo, as confusões entre **glioma** e **notumor**, assim como entre **pituitary** e **meningioma**, destacam a necessidade de otimizações adicionais no modelo, como o refinamento do treinamento, balanceamento das classes no conjunto de dados ou a aplicação de técnicas avançadas de extração de características para minimizar os erros de classificação e aumentar a acurácia global.




Figura 6 Matriz de confusão do modelo ResNet50

A Figura 6 revela uma leve mudança no desempenho do modelo, com as classificações corretas distribuídas da seguinte forma: **glioma** com 62 amostras, **meningioma** com 58, **notumor** com 121 e **pituitary** com 92. Destaca-se uma melhoria expressiva na classe **pituitary**, que alcançou 92 classificações corretas, evidenciando um avanço em relação às matrizes anteriores.

Os principais erros de classificação foram observados na classe **glioma**, que foi confundida com **notumor** em 95 casos e com **pituitary** em 97 casos. A classe **meningioma** apresentou confusões significativas, sendo classificada erroneamente como **notumor** em 116 casos e como **pituitary** em 84 casos. Já a classe **notumor**, embora continue sendo a mais bem classificada, apresentou confusões com **glioma** (99 casos) e **meningioma** (62 casos).

Como conclusão, em todas as matrizes, a classe notumor apresenta o maior número de classificações corretas, o que sugere que o modelo é mais eficiente para esta classe. O glioma e meningioma são frequentemente confundidos com outras classes, indicando que suas características podem estar sobrepostas nos dados ou que o modelo precisa de ajustes. As classes problemáticas como a glioma e pituitary frequentemente são confundidos entre si e com notumor. A classe meningioma também apresenta baixa precisão devido a confusão com notumor e outras classes.

Algumas melhorias são necessárias como o ajuste no treinamento, garantindo maior equilíbrio entre as classes e verificando a qualidade dos exemplos fornecidos ao modelo. A implementação de técnicas mais avançadas para identificação de características que melhor diferenciem as classes. E por último aprimoramento no modelo, utilizando métodos de regularização, ensembles ou redes mais profundas para melhorar o aprendizado das características.

IV. Conclusões

O presente trabalho abordou a implementação e avaliação de modelos de redes neurais convolucionais, como ResNet-50 e MobileNetV2, aplicados à classificação de imagens médicas em diferentes categorias. A metodologia utilizada englobou desde o pré-processamento das imagens até a aplicação de técnicas avançadas de aprendizado profundo, incluindo data augmentation, regularização e ajuste de hiperparâmetros. Além disso, foram empregados conjuntos de dados estruturados em pastas de treino e teste para garantir a robustez da análise.

Os resultados obtidos demonstraram que os modelos são capazes de atingir níveis de precisão elevados, reforçando sua aplicabilidade em cenários médicos, onde a classificação precisa é essencial para suporte diagnóstico. A utilização de arquiteturas modernas, aliada ao uso eficiente de recursos computacionais, mostrou-se fundamental para equilibrar desempenho e custo computacional, especialmente em sistemas limitados, como o utilizado nesta pesquisa.

A relevância deste trabalho reside no potencial impacto que tais modelos podem gerar na área da saúde, fornecendo ferramentas rápidas e precisas para análise de imagens médicas. Apesar dos avanços alcançados, desafios permanecem, como a necessidade de maiores volumes de dados para treinamento e a redução de vieses nos modelos.

Como trabalhos futuros, sugere-se a aplicação das arquiteturas desenvolvidas em outros tipos de imagens médicas e a integração com sistemas de apoio à decisão clínica, ampliando sua utilização em diferentes contextos. Além disso, a adaptação para dispositivos móveis pode potencializar sua acessibilidade, especialmente em regiões com recursos limitados.

V. Referências

AWS, A. O que é Aprendizado profundo? Explicações sobre Aprendizado profundo - AWS. 2023.

BROWNLEE, J. What is Deep Learning? 2016.

MAZZOLA, A. A. Ressonância magnética: princípios de formação da imagem e aplicações em imagem funcional. Revista brasileira de física médica, v. 3, n. 1, p. 117–129, 2009.

M. Nickparvar, “Brain tumor mri dataset,” 2021. [Online]. Available: <https://www.kaggle.com/dsv/2645886>

SPRINGER. Artificial intelligence in medicine. 2022.

TANG, X. The role of artificial intelligence in medical imaging research. BJR Open, v. 2, p. 20190031, 11 2020.